

ANALYSE ET PRÉDICTION DE L'AFFLUENCE EN LIGUE 1

BART François - M1 SIAD

SOMMAIRE

Introduction.....	3
1. Nettoyage et préparation des données	4
1.1. Présentation des sources de données	4
1.2. Justification du choix des variables.....	5
1.3. Traitement des données manquantes et aberrantes.....	5
1.4. Enrichissement des variables	5
2. Étude préalable des données	7
2.1. Analyse univariée.....	7
2.2. Analyse bivariée	8
2.3. Analyse des corrélations	10
3. Prédiction de l'affluence	11
3.1 Analyse du modèle.....	11
3.2 Résultat du modèle	12
3.3. Validation du modèle sur des matchs réels	13
Conclusion	14
Annexe	15

Introduction

L'étude porte sur l'analyse des matchs de football de Ligue 1 et vise à prédire l'affluence d'un match en fonction de différents facteurs. L'objectif est donc d'identifier les éléments qui jouent un rôle dans le nombre spectateurs présents lors d'un match. Par la suite, cette analyse nous permettra de construire un modèle permettant de prédire cette affluence.

Pour ce faire, nous disposons de deux sources de données : un premier fichier contenant des informations détaillées sur les matchs (équipes, cotes, performances, etc.) et un second regroupant des données sur les stades (capacité, affluence, localisation, date et heure des matchs). Ces données couvrent plusieurs saisons depuis les années 2000 sur de nombreuses ligues du monde.

La première étape de cette étude consiste à nettoyer les données, en détectant et corrigeant les éventuelles valeurs manquantes ou aberrantes. En utilisant différentes méthodes comme la visualisation graphique de nos données. Nous effectuerons aussi des ajouts de données via de nouvelles variables afin que notre modèle soit plus puissant.

Nous allons dans un second temps réaliser une étude descriptive des données fournies afin d'en déterminer les informations principales et d'identifier les comportements récurrents dans l'affluence d'un match selon la période, les clubs, l'heure ou encore la forme de l'équipe. Nous déterminerons également les potentielles relations entre les variables afin de ne garder que les plus représentatives pour établir notre modèle.

Dans la dernière partie, nous construirons un modèle de régression pour prédire l'affluence en fonction des variables retenues. Ce modèle sera ensuite appliqué à une sélection de matchs, afin d'évaluer sa capacité prédictive et de le comparer à l'affluence réel de ces mêmes matchs.

1. Nettoyage et préparation des données

1.1. Présentation des sources de données

Pour cette étude, nous avons utilisé deux bases de données issues d'un site open source nommé Kaggle. Ici ces deux fichiers couvrent un grand nombre de compétitions et de championnats et fournissent des informations sur les différents matchs disputés :

- **Base "Match"** : cette base contient les résultats de matchs de football disputés entre 2000 et 2025 dans 27 pays et 42 ligue, soit environ 230 000 lignes pour 42 variables. Elle inclut des indicateurs liés aux performances des équipes, aux cotes des paris, et a un classements « elo », un système d'évaluation du niveau d'une équipe, mis à jour deux fois par mois.

Pour notre analyse, nous avons conservé uniquement les colonnes suivantes :

- HomeTeam, AwayTeam : noms des équipes
- MatchDate, MatchTime : date et heure du match
- HomeElo, AwayElo : indices Elo des deux équipes
- Form3Home, Form5Home, Form3Away, Form5Away : forme récente des équipes sur leurs 3 ou 5 derniers matchs
- OddHome, OddDraw, OddAway : cotes des paris pour chaque résultats du match
- Over25, Under25, MaxHome, MaxDraw, MaxAway, MaxOver25, MaxUnder25 : autres cotes sur différentes probabilités sur le match
- **Base "Foot"** : cette seconde base contient elle aussi de nombreuses variables sur l'ensemble des données pouvant être récolter lors d'un match allant du nombre de passes réussis au nombre de tacles et même du nombre de changements réalisés par chaque équipe. Elle regroupe environ 100 000 lignes pour 91 variables, couvrant plusieurs championnats européens. Elle fournit des détails sur le lieu, la fréquentation, et d'autres statistiques match par match.

Les variables retenues ici sont :

- Country, League : pays et ligue du match
- home_team, away_team : noms des équipes (à harmoniser avec la première base)
- season_year, Date_day, Date_hour : informations de calendrier
- venue : nom du stade
- capacity : capacité totale du stade
- attendance : affluence réelle mesurée le jour du match

Dans notre étude, nous nous sommes seulement concentrés sur les données de la Ligue 1 car cela nous sembler être le championnat le plus facile à comprendre les résultats mais notre base est adaptable à n'importe quel championnat disponible dans ces bases.

1.2. Justification du choix des variables

L'objectif étant de modéliser l'affluence dans les stades, les variables choisies répondent à deux grands critères :

- **Pertinence explicative** : niveau de l'équipe, forme récente, importance du match, cotes de paris (qui traduisent une anticipation collective), etc.
- **Contexte du match** : jour et heure de rencontre, capacité du stade, équipe à domicile, etc.

Avant toute analyse, un travail important de nettoyage et de structuration a été nécessaire pour croiser ces deux jeux de données, les harmoniser, corriger les incohérences et construire des variables supplémentaires utiles à la modélisation. Ces étapes sont détaillées dans la section suivante.

1.3. Traitement des données manquantes et aberrantes

Une fois les deux bases filtrées sur la Ligue 1, nous avons procédé à une vérification des données manquantes et aberrantes

Dans la base "Match", certaines variables présentaient des valeurs manquantes, notamment sur les côtes de paris et les scores Elo. Ces valeurs étant essentielles pour notre analyse, nous avons choisi de supprimer les lignes incomplètes. Ce choix se justifie par l'impossibilité de les estimer de manière fiable dans notre modèle.

Concernant la base "Foot", les informations d'affluence (attendance) étaient manquantes pour une partie des saisons, notamment avant 2015, de plus pour la saison 2020/2021, fortement impactée par les restrictions sanitaires liées au COVID-19, nous avons décidé de supprimer les données car elles ne reflètent pas un contexte "normal" d'affluence, la moyenne de spectateurs durant le Covid était 6 fois inférieur à la normale.

Dans cette base nous avons aussi découvert que l'affluence était inexistante pour le mois d'octobre peu importe la saison et aussi que dans certains cas, la capacité du stade était inférieure à l'affluence pour un match. Cette erreur provient directement de la base de données est nous avons donc décidé de supprimer ces incohérences.

1.4. Enrichissement des variables

Une fois les données filtrées et nettoyées, nous avons créé de nouvelles variables à partir des informations existantes. L'objectif était d'avoir des informations plus précises sur les matchs et d'identifier des facteurs susceptibles d'influencer l'affluence.

Voici les principales variables ajoutées :


- **MatchDay** : correspond au jour de la semaine du match (ex. : samedi, dimanche). Cela permet d'analyser l'impact des jours ouvrés ou du week-end sur la fréquentation.
- **MatchMonth** et **MatchYear** : indiquent respectivement le mois et l'année du match, ce qui est utile pour repérer d'éventuelles tendances saisonnières ou l'évolution globale de l'affluence.

- MatchHour : extraite à partir de l'horaire initial, cette variable garde uniquement l'heure du coup d'envoi et plus les minutes
- IsWeekend : variable binaire qui prend la valeur 1 si le match se joue un samedi ou dimanche, 0 sinon. L'objectif est d'observer si les matchs de week-end attirent plus de spectateurs.
- EloDiff : mesure l'écart de niveau entre les deux équipes, à partir des scores Elo.
- occupancy_rate : correspond au taux de remplissage du stade, calculé comme le ratio entre l'affluence réelle (attendance) et la capacité totale du stade (capacity).

Ces variables ont été ajoutées pour mieux décrire la réalité d'un match et comprendre les comportements des spectateurs. Elles sont également essentielles dans la phase de modélisation, où l'on cherchera à identifier les déterminants les plus influents de l'affluence.



2. Étude préalable des données

2.1. Analyse univariée




Le premier graphique montre la répartition du nombre de spectateurs par match. On observe une distribution asymétrique à droite, avec une majorité de matchs entre 10 000 et 30 000 spectateurs. Très peu de matchs dépassent les 50 000. Cela traduit probablement la variété de capacités des stades de Ligue 1, allant de petites enceintes à de très grands stades comme celui du PSG ou de l'OM.

Le diagramme de densité de la variable EloDiff illustre la répartition des écarts de niveau entre les équipes. On constate une courbe en cloche centrée autour de zéro, ce qui signifie que la majorité des matchs opposent des équipes de niveau relativement proche. Ce point est intéressant, car les matchs déséquilibrés pourraient avoir un impact sur l'affluence (moins de suspense).



Ce graphique montre que la plupart des matchs ont lieu le samedi et le dimanche, ce qui est cohérent avec l'organisation d'une journée de championnat. Très peu de rencontres sont jouées en semaine, à l'exception du mercredi et du vendredi. Cela renforce l'idée que le jour du match est une variable clé pour analyser l'affluence.


2.2. Analyse bivariable



Ce graphique révèle des différences notables selon l'horaire du match :


- Les matchs programmés à 14h ou 16h enregistrent une affluence plus faible.
- Les matchs en soirée (18h, 21h, 22h) attirent plus de monde, avec un pic à 22h (31 575 spectateurs en moyenne).

Cela peut s'expliquer par la disponibilité du public en fin de journée, ainsi que par l'attractivité des affiches diffusées le soir (matchs en prime time).




Ce graphique montre l'évolution du taux de remplissage moyen des stades par saison. Globalement, il varie entre 64 % et 83 %, avec des fluctuations marquées.

La saison 2021/2022 enregistre une nette baisse à 64 %, probablement en lien avec les restrictions sanitaires encore en vigueur. Ensuite, la tendance repart à la hausse : 77 % en 2022/2023, 83 % en 2023/2024, puis un léger recul à 80 % en 2024/2025.



L'évolution de l'affluence moyenne saison par saison montre une tendance globale à la hausse, avec un rebond significatif après la saison 2021/2022.

On atteint un pic sur les deux dernières saisons disponibles (2023/2024 et 2024/2025) avec près de 27 000 spectateurs en moyenne. Cela reflète probablement une dynamique de reprise post-COVID, combinée à l'attractivité croissante de certains clubs.



L'analyse par mois fait ressortir des variations saisonnières :

- Les mois de mai, avril, mars et février sont ceux où l'affluence est la plus élevée.
- À l'inverse, juin et janvier affichent les plus faibles moyennes, probablement en lien avec la météo ou aussi à la fin du championnat donc une plus grande attirance pour les matchs à enjeux.

Cela suggère que certains mois sont naturellement plus favorables à la fréquentation.

2.3. Analyse des corrélations

Avant de passer à la modélisation, j'ai réalisé un test de corrélation entre les variables numériques du jeu de données. L'idée était de repérer celles qui semblaient liées à l'affluence, mais aussi de détecter celles qui se recoupaient trop entre elles. En effet, un modèle trop chargé en variables similaires risque de perdre en fiabilité et en lisibilité.

Dans un premier temps, j'ai intégré l'ensemble des indicateurs disponibles : les scores Elo des équipes, leur forme récente, les différentes cotes de paris, la capacité des stades, ou encore l'heure et la date du match. Cette première matrice, un peu dense, a permis de mettre en évidence certaines tendances. Par exemple, la capacité du stade et les cotes de victoire à domicile apparaissaient assez logiquement liées à l'affluence. En revanche, d'autres variables comme certaines cotes "alternatives" ou les formes sur trois matchs semblaient apporter peu d'information supplémentaire.

À partir de ce constat, j'ai affiné la sélection en gardant uniquement les variables les plus parlantes, à la fois d'un point de vue statistique et métier. J'ai ainsi retiré les doublons et les variables construites spécifiquement pour l'exploration, comme la différence de niveau entre les équipes ou le taux de remplissage. Une deuxième matrice, plus épurée, a été générée avec cette sélection réduite. C'est elle qui a servi de base pour la modélisation.

Les résultats complets de ces deux analyses sont présentés en [annexe](#), mais ce qu'il faut retenir, c'est que ce travail a permis de clarifier le jeu de données, de se concentrer sur l'essentiel, et de poser des bases solides pour construire un modèle prédictif fiable et cohérent.

3. Prédiction de l'affluence

3.1 Analyse du modèle

Dans la dernière partie de notre projet, nous avons construit un modèle capable de prédire l'affluence attendue lors d'un match de Ligue 1. Le but était d'estimer, à partir d'informations disponibles avant le match, combien de spectateurs seraient présents dans le stade.

Pour cela, nous avons choisi d'utiliser une régression linéaire multiple, un modèle simple mais bien adapté à notre objectif. Il permet de comprendre l'impact de plusieurs variables en même temps sur l'affluence et reste facilement interprétable.

Le modèle s'appuie uniquement sur des informations disponibles en amont du match, ce qui garantit sa réutilisabilité en conditions réelles.

Parmi les plus importantes :

- Les équipes en présence, en particulier l'équipe à domicile, ont un poids important. Certains clubs attirent naturellement plus de public, soit par leur notoriété, soit par leur base de supporters locale.
- Les scores Elo permettent d'évaluer la force relative des équipes à un instant donné. Un match entre deux équipes bien classées ou très déséquilibrées peut modifier l'intérêt perçu.
- Les cotes de paris (victoire, nul, défaite) reflètent l'anticipation du résultat, mais aussi l'importance ou l'incertitude d'un match. Un match jugé "jouable" à domicile attire souvent plus de monde.
- La capacité du stade est un facteur structurel évident, mais elle est insuffisante à elle seule : certains stades ne sont jamais pleins, d'autres affichent souvent complet.
- Le moment du match (mois, heure, week-end ou non) joue aussi un rôle. Les matchs en soirée et les rencontres du week-end tendent à attirer plus de public.

Toutes ces variables ont été préparées en amont pour être compatibles avec le modèle. Les variables qualitatives (comme les noms d'équipes) ont été transformées en variables factorielles afin d'être analysées.

3.2 Résultat du modèle

Le modèle de régression permet de mesurer l'impact de chaque variable sur l'affluence, toutes choses égales par ailleurs. Les résultats sont exprimés par rapport à une situation de référence, à savoir : un match à domicile d'Ajaccio, joué un lundi de janvier, en semaine, à une heure de base fixée par le modèle.

Certains effets ressortent de manière très nette :


- Les clubs les plus populaires attirent logiquement beaucoup plus de monde. Par exemple, un match à domicile de l'Olympique Lyonnais augmente l'affluence attendue d'environ 13 000 spectateurs par rapport à un match similaire joué à Ajaccio. Le Paris Saint-Germain et Marseille ont des effets encore plus marqués, ce qui confirme leur pouvoir d'attraction dans les stades.
- Le moment du match joue aussi un rôle important. Passer d'un match joué en semaine à un match le week-end (samedi ou dimanche) fait grimper l'affluence de plus de 4 500 spectateurs en moyenne. Ce résultat confirme que le public est beaucoup plus disponible le week-end, et probablement plus enclin à se déplacer.
- L'horaire influence également la fréquentation : un match joué en soirée à 21h attire en moyenne 5 200 spectateurs de plus qu'un match à l'heure de référence. Les créneaux du soir, souvent associés à de meilleures affiches télévisées, semblent donc plus attractifs.
- Le mois de l'année n'est pas neutre non plus. Par rapport à un match joué en janvier, les rencontres disputées en mai enregistrent une hausse moyenne de 6 000 spectateurs, probablement en raison des enjeux de fin de saison et de la météo plus favorable.
- La capacité du stade reste un facteur clé, mais son effet est modéré par d'autres variables : certains clubs remplissent presque toujours leur enceinte, d'autres peinent à l'utiliser pleinement, quel que soit leur potentiel.

Ces résultats montrent que le modèle parvient à capter des effets concrets, cohérents avec l'intuition métier, tout en mettant en évidence l'impact réel et quantifié de chaque facteur sur l'affluence attendue.

3.3. Validation du modèle sur des matchs réels

Pour tester l'efficacité du modèle, nous avons réalisé une estimation de l'affluence sur un échantillon de 80 matchs de Ligue 1 de la saison 2024/2025. Pour chaque rencontre, les variables connues à l'avance (équipes en présence, cotes, horaires, etc.) ont été intégrées dans le modèle afin de prédire le nombre de spectateurs attendus.

Le graphique ci-dessous compare, pour chaque match, l'affluence réellement observée (en rouge) à celle prédite par le modèle (en bleu). Chaque point représente un match.



On observe que, dans l'ensemble, le modèle suit bien la tendance générale. Il parvient à détecter les fortes affluences lors des grandes affiches, comme il anticipe aussi les matchs moins suivis, souvent disputés par des clubs plus modestes ou à des horaires moins favorables.

Cependant, quelques écarts notables apparaissent, notamment sur certains matchs où le contexte ne peut pas être capté par les données utilisées dans le modèle. Par exemple, lors de la rencontre entre Saint-Étienne et Le Havre, bien que le modèle estimait une affluence de plus de 28 000 spectateurs (ce qui aurait été cohérent avec un samedi soir au stade Geoffroy-Guichard), la réalité a été bien différente : seulement 16 958 spectateurs étaient présents. La cause ? Deux des quatre tribunes étaient fermées à la suite de sanctions, empêchant une partie des supporters d'accéder au stade.

Ce type d'élément – grève de supporters, huis clos partiel, interdictions de déplacement, ou encore rivalités spécifiques (comme les derbys) – échappe au champ du modèle, car il ne figure pas dans les données à disposition. Ce sont des facteurs humains ou contextuels qui influencent fortement la fréquentation, mais qui restent difficiles à anticiper sans sources externes ou données événementielles.

Malgré cela, cette simulation montre que le modèle offre une base solide de prévision et permettrait d'anticiper la fréquentation avec un bon niveau de précision dans des conditions normales.

Conclusion

Ce projet avait pour ambition de comprendre ce qui influence réellement l'affluence lors des matchs de Ligue 1, en s'appuyant sur des données accessibles avant chaque rencontre. En partant de sources ouvertes et en nettoyant rigoureusement les informations, nous avons pu construire une base exploitable, croisant des éléments sportifs, logistiques et temporels.

L'analyse statistique a mis en évidence des tendances fortes et cohérentes : certains clubs attirent naturellement plus de spectateurs, les matchs du week-end sont plus suivis que ceux en semaine, et les horaires de soirée ont un effet positif. Des facteurs comme la forme récente des équipes, leur niveau Elo ou les cotes des bookmakers apportent aussi de l'information utile sur l'intérêt suscité par chaque rencontre.

Sur cette base, nous avons développé un modèle de régression capable d'estimer l'affluence avec une précision satisfaisante. Testé sur des matchs de la saison 2024/2025, il montre une bonne capacité à reproduire les niveaux réels de fréquentation, tout en restant simple à utiliser. Bien sûr, certaines limites demeurent : des événements ponctuels (sanctions, météo, conflits avec les supporters) ne peuvent pas être anticipés par le modèle en l'état.

Malgré cela, les résultats obtenus démontrent qu'un modèle bien construit, s'appuyant sur des données propres et bien choisies, peut fournir une aide précieuse pour anticiper l'affluence. Dans une logique opérationnelle, il pourrait être utilisé pour planifier les ressources, adapter la stratégie tarifaire ou préparer les dispositifs d'accueil autour des stades.

En résumé, ce projet montre qu'à partir de données simples et accessibles, on peut dégager des enseignements concrets et utiles, à condition de bien les structurer, les comprendre et les modéliser avec rigueur.

Annexe

Première Matrice de Corrélation :

	HomeElo	AwayElo	Form3Home	Form3Away	Form5Home	Form5Away	OddHome	OddDraw	OddAway	Over25	Under25	MaxHome	MaxDraw	MaxAway	MaxOver25	MaxUnder25	capacity	attendance	MatchMonth	MatchYear	MatchHour	Weekend	EloDiff	occupancy_rate
HomeElo	1																							
AwayElo	-0,00432	1																						
Form3Home	0,50901	0,04727	1																					
Form5Home	0,610238	0,019529	0,8334	1																				
Form3Away	0,031421	0,500744	0,068548	0,049644	1																			
Form5Away	0,023983	0,603472	0,067656	0,039295	0,825895	1																		
OddHome	-0,37624	0,691494	-0,17296	-0,2282	0,348334	0,415323	1																	
OddDraw	0,603802	0,25184	0,317971	0,368347	0,038626	0,021257	0,080940	1																
OddAway	0,68676	-0,38838	0,355359	0,431713	-0,17034	-0,22647	-0,44655	0,805375	1															
Over25	-0,51969	-0,25074	-0,27164	-0,30473	-0,13005	-0,1444	-0,13861	-0,68693	-0,40081	1														
Under25	0,58004	0,199054	0,302499	0,344483	0,123283	0,130864	0,123339	0,869373	0,586823	-0,88782	1													
MaxHome	-0,35843	0,677702	-0,16432	-0,21664	0,342129	0,408353	0,993115	0,105222	-0,42481	-0,1484	0,138851	1												
MaxDraw	0,597166	0,011151	0,314332	0,36478	0,035272	0,017809	0,064943	0,991596	0,822017	-0,67241	0,86571	0,087846	1											
MaxAway	0,649607	-0,34836	0,328821	0,398436	-0,1437	-0,19289	-0,39017	0,827046	0,979156	-0,39299	0,596938	-0,37098	0,844589	1										
MaxOver25	-0,51465	-0,24863	-0,26832	-0,30039	-0,12622	-0,14192	-0,13755	-0,67968	-0,39429	0,997702	-0,88049	-0,14712	-0,66512	-0,38646	1									
MaxUnder25	0,577885	0,192822	0,302002	0,344755	0,123534	0,129952	0,120936	0,873148	0,595852	-0,87432	0,997802	0,137137	0,87147	0,607881	-0,86632	1								
capacity	0,545265	-0,02065	0,286491	0,330813	0,029221	0,023869	-0,24816	0,299716	0,376809	-0,30235	0,29647	-0,23447	0,296983	0,341725	-0,29911	0,295581	1							
attendance	0,591184	0,118828	0,336279	0,378784	0,10075	0,098083	-0,14827	0,409109	0,402505	-0,40567	0,422021	-0,13694	0,404174	0,381837	-0,4027	0,419803	0,85991	1						
MatchMonth	0,007207	0,004851	-7,1E-05	0,002601	0,003999	0,009776	-0,00054	0,006568	0,000146	-0,00325	0,001812	0,006772	0,004579	0,00555	-0,00229	0,001276	-0,00197	-0,00965	1					
MatchYear	0,132538	0,117411	0,023144	0,009325	-0,01848	-0,01465	0,00411	0,086443	-0,05746	-0,2977	0,21437	-0,00163	0,07167	-0,05968	-0,31547	0,189153	0,002603	0,110267	-0,13535	1				
MatchHour	0,089043	0,082064	0,083424	0,089769	0,085128	0,067334	0,012928	0,079464	0,05483	-0,08292	0,113111	0,014427	0,073927	0,057112	-0,07523	0,116221	0,113797	0,1307	0,030977	-0,20889	1			
IsWeekend	-0,03736	-0,08321	-0,02455	-0,03148	-0,08397	-0,08065	-0,06416	-0,05673	-0,01351	0,052425	-0,04895	-0,06578	-0,04936	-0,02031	0,051994	-0,04833	-0,03556	-0,01173	-0,06403	0,031375	-0,32803	1		
EloDiff	0,713372	-0,70386	0,328447	0,419795	-0,3286	-0,40587	-0,75188	0,41126	0,767022	-0,19345	0,272535	-0,72954	0,41638	0,705571	-0,19134	0,275371	0,401802	0,336657	0,00172	0,012578	0,005742	0,031772	1	
occupancy_rate	0,183644	0,289787	0,154391	0,160013	0,143041	0,160292	0,172442	0,253717	0,098775	-0,25976	0,287148	0,170965	0,248166	0,117903	-0,26097	0,2844	0,092422	0,544204	-0,01231	0,191383	0,056268	0,017124	-0,07263	1

Cette matrice permet d'observer les liens entre les variables numériques du jeu de données. On remarque que certaines variables sont fortement corrélées entre elles, notamment les différentes cotes de paris, ce qui crée des redondances. La capacité du stade est fortement liée à l'affluence, ce qui est attendu, tout comme le score Elo de l'équipe à domicile et la cote de victoire à domicile, qui semblent avoir un lien modéré mais réel avec le nombre de spectateurs.

En revanche, certaines variables comme occupancy_rate, EloDiff ou les formes sur 3 matchs sont soit trop corrélées à d'autres, soit peu explicatives. Elles ont donc été retirées de la sélection finale pour éviter la redondance et améliorer la lisibilité du modèle.

Deuxième Matrice de Corrélation :

	HomeElo	AwayElo	Form5Home	Form5Away	OddHome	OddDraw	OddAway	MaxOver25	capacity	MatchMonth	MatchYear	MatchHour
HomeElo	1											
AwayElo	-0,004317372	1										
Form5Home	0,610238416	0,019529174	1									
Form5Away	0,023982738	0,603472063	0,039295283	1								
OddHome	-0,376244173	0,691494078	-0,228197196	0,415323082	1							
OddDraw	0,603802018	0,25183722	0,368347003	0,021257204	0,080947578	1						
OddAway	0,686759798	-0,398383851	0,431712781	-0,226468421	-0,446553861	0,805374702	1					
MaxOver25	-0,514652548	-0,248630799	-0,300392886	-0,14191557	-0,137554953	-0,6796777	-0,394285553	1				
capacity	0,545265463	-0,020654174	0,330812567	0,023869499	-0,248163571	0,299715541	0,376808801	-0,299108343	1			
MatchMonth	0,007207187	0,004850734	0,002600557	0,00977557	-0,000535641	0,006568299	0,000146199	-0,002587048	-0,001966198	1		
MatchYear	0,133538245	0,117410567	0,009325122	-0,014650592	0,004109575	0,086443252	-0,057461505	-0,315465546	0,003603028	-0,135352703	1	
MatchHour	0,089042735	0,082063669	0,089768522	0,067334082	0,012927598	0,079464185	0,054830463	-0,075225801	0,113797455	0,030977127	-0,208885779	1
IsWeekend	-0,037364872	-0,083212232	-0,031482378	-0,080648765	-0,064164499	-0,056729285	-0,013506694	0,051993685	-0,035561181	-0,064027725	0,031374729	-0,328029999

Cette matrice présente les corrélations entre les variables retenues pour la modélisation. Les variables fortement redondantes ou peu explicatives ont été retirées à ce stade.

On observe que certaines variables gardent une corrélation modérée avec l'affluence, comme capacity, HomeElo ou OddHome, ce qui confirme leur intérêt pour la suite de l'analyse. Les autres variables, comme l'heure du match ou la forme récente des équipes, affichent des corrélations plus faibles mais restent pertinentes dans un cadre combiné.

Cette sélection finale permet de travailler sur un modèle plus simple, sans perte d'information essentielle.

Extrait de la sortie du modèle :

Coefficients:									
	Estimate	Std. Error	t value	Pr(> t)					
(Intercept)	-7.582e+05	1.038e+05	-7.301	3.84e-13 ***	AwayTeamNice	-1.015e+02	1.391e+03	-0.073	0.941837
HomeTeamAmiens	5.919e+03	3.095e+03	1.912	0.055929 .	AwayTeamNimes	-1.526e+01	1.558e+03	-0.010	0.992186
HomeTeamAngers	9.515e+03	7.537e+03	1.262	0.206922 .	AwayTeamParis SG	5.971e+03	1.703e+03	3.505	0.000465 ***
HomeTeamAuxerre	1.280e+04	7.024e+03	1.823	0.068442 .	AwayTeamReims	-1.462e+03	1.371e+03	-1.066	0.286553
HomeTeamBastia	8.791e+03	5.718e+03	1.538	0.124286	AwayTeamRennes	-1.060e+03	1.386e+03	-0.765	0.444373
HomeTeamBordeaux	3.709e+04	2.417e+04	1.534	0.125084	AwayTeamSt Etienne	1.013e+03	1.393e+03	0.727	0.467257
HomeTeamBrest	7.558e+03	5.114e+03	1.478	0.139568	AwayTeamStrasbourg	-1.657e+03	1.358e+03	-1.220	0.222685
HomeTeamCaen	1.730e+04	8.636e+03	2.003	0.045315 *	AwayTeamToulouse	-7.896e+02	1.348e+03	-0.586	0.557968
HomeTeamClermont	1.767e+03	2.470e+03	0.715	0.474590	AwayTeamTroyes	-8.750e+02	1.395e+03	-0.627	0.530593
HomeTeamDijon	9.385e+03	5.273e+03	1.780	0.075227 .	HomeELO	1.310e+01	2.629e+00	4.981	6.76e-07 ***
HomeTeamGuingamp	1.390e+04	7.767e+03	1.789	0.073729 .	AwayELO	6.546e+00	2.629e+00	2.490	0.012842 *
HomeTeamLe Havre	2.243e+04	1.212e+04	1.850	0.064375 .	Form5Home	1.337e+02	3.778e+01	3.538	0.000411 ***
HomeTeamLens	4.283e+04	2.141e+04	2.001	0.045518 *	Form5Away	5.850e+01	3.791e+01	1.543	0.122905
HomeTeamLille	5.112e+04	2.995e+04	1.707	0.088028 .	OddHome	-1.363e+02	1.653e+02	-0.824	0.409915
HomeTeamLorient	1.002e+04	6.181e+03	1.621	0.105200	OddDraw	-2.726e+01	3.544e+02	-0.077	0.938695
HomeTeamLyon	6.564e+04	3.640e+04	1.803	0.071450 .	OddAway	1.837e+02	1.214e+02	1.513	0.130419
HomeTeamMarseille	7.949e+04	4.227e+04	1.880	0.060173 .	MaxOver25	5.754e+02	5.376e+02	1.070	0.284550
HomeTeamMetz	2.279e+04	1.465e+04	1.555	0.120013	capacity	-6.519e-01	7.169e-01	-0.909	0.363251
HomeTeamMonaco	3.081e+03	7.407e+03	0.416	0.677477	MatchMonth2	2.890e+03	4.077e+02	7.088	1.78e-12 ***
HomeTeamMontpellier	1.160e+04	8.762e+03	1.323	0.185808	MatchMonth3	2.965e+03	4.495e+02	6.597	5.11e-11 ***
HomeTeamNancy	1.777e+04	8.548e+03	2.079	0.037746 *	MatchMonth4	4.013e+03	4.231e+02	9.484	< 2e-16 ***
HomeTeamNantes	3.397e+04	1.932e+04	1.759	0.078787 .	MatchMonth5	5.323e+03	4.762e+02	11.178	< 2e-16 ***
HomeTeamNice	2.893e+04	1.993e+04	1.452	0.146761	MatchMonth6	4.332e+03	1.701e+03	2.548	0.010906 *
HomeTeamNimes	1.212e+04	7.316e+03	1.657	0.097639 .	MatchMonth8	3.001e+03	4.259e+02	7.047	2.37e-12 ***
HomeTeamParis SG	5.683e+04	2.857e+04	1.990	0.046757 *	MatchMonth9	2.251e+03	4.166e+02	5.403	7.19e-08 ***
HomeTeamReims	1.202e+04	9.149e+03	1.314	0.188851	MatchMonth11	2.795e+03	4.341e+02	6.438	1.45e-10 ***
HomeTeamRennes	2.870e+04	1.536e+04	1.868	0.061914 .	MatchMonth12	2.439e+03	4.345e+02	5.614	2.20e-08 ***
HomeTeamSt Etienne	4.005e+04	2.410e+04	1.662	0.096623 .	MatchYear	3.632e+02	5.145e+01	7.060	2.16e-12 ***
HomeTeamStrasbourg	2.674e+04	1.275e+04	2.097	0.036087 *	MatchHour	9.441e+01	4.888e+01	1.932	0.053530 .
HomeTeamToulouse	2.683e+04	1.772e+04	1.514	0.130204	Isweekend1	8.492e+02	2.610e+02	3.254	0.001155 **
HomeTeamTroyes	1.142e+04	8.719e+03	1.310	0.190202	---				
AwayTeamAmiens	-1.086e+03	1.441e+03	-0.754	0.451047	signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1				
AwayTeamAngers	-1.379e+03	1.340e+03	-1.029	0.303719	Residual standard error: 4883 on 2450 degrees of freedom				
AwayTeamAuxerre	3.804e+02	1.657e+03	0.230	0.818496	Multiple R-squared: 0.8779, Adjusted R-squared: 0.8739				
AwayTeamBastia	-1.182e+03	1.585e+03	-0.746	0.455893	F-statistic: 217.6 on 81 and 2450 DF, p-value: < 2.2e-16				
AwayTeamBordeaux	-2.527e+02	1.392e+03	-0.182	0.855931					
AwayTeamBrest	-1.894e+03	1.410e+03	-1.343	0.179427					
AwayTeamCaen	-1.212e+03	1.405e+03	-0.862	0.388514					
AwayTeamClermont	-1.254e+03	1.439e+03	-0.871	0.383687					
AwayTeamDijon	-1.935e+03	1.411e+03	-1.371	0.170440					
AwayTeamGuingamp	-1.327e+03	1.412e+03	-0.940	0.347299					
AwayTeamLe Havre	1.430e+02	1.695e+03	0.084	0.932787					
AwayTeamLens	9.416e+02	1.517e+03	0.621	0.534762					
AwayTeamLille	-9.479e+02	1.392e+03	-0.681	0.496016					
AwayTeamLorient	-1.926e+03	1.386e+03	-1.390	0.164783					
AwayTeamLyon	2.068e+03	1.463e+03	1.414	0.157404					
AwayTeamMarseille	4.142e+03	1.432e+03	2.892	0.003862 **					
AwayTeamMetz	-1.578e+03	1.372e+03	-1.151	0.249965					
AwayTeamMonaco	3.469e+02	1.455e+03	0.238	0.811584					
AwayTeamMontpellier	-1.384e+03	1.362e+03	-1.016	0.309746					
AwayTeamNancy	-3.172e+03	1.746e+03	-1.817	0.069415 .					
AwayTeamNantes	-5.396e+02	1.345e+03	-0.401	0.688247					

Ce tableau résume les résultats de la régression utilisée pour prédire l'affluence. Chaque coefficient indique l'impact d'une variable sur le nombre de spectateurs, en tenant les autres constantes. Par exemple, un coefficient positif pour HomeTeamLyon signifie que Lyon attire plus de public qu'Ajaccio, qui sert ici de référence.

Un effet est considéré comme significatif si la p-value est inférieure à 0,05, ce qui est signalé par des étoiles.

Le R² de 0,878 montre que le modèle explique 88 % de la variation de l'affluence, ce qui est excellent compte tenu des variables disponibles. La p-value globale très faible confirme la solidité statistique du modèle.

Extrait du fichier Excel comportant les prédictions d’affluence :

HomeTea	AwayTea	HomeE	AwayE	Form5Home	Form5Away	OddHome	OddAway	OddDraw	MaxOver	season_year	venue	capac	MatchDay	MatchMonth	MatchYear	MatchDay	MatchMonth	PredictedAttendance	attendance	Ecart_Affluence
Monaco	Brest	1795,06	1706,26	7	7	1,52	4,38	6,3	1,79	2024/2025	Stade Louis II (Monaco)	18523	vendredi	11	2024	21	16	8749	5800	2949
Monaco	Le Havre	1776,65	1560,89	13	6	1,37	5,13	7,99	1,63	2024/2025	Stade Louis II (Monaco)	18523	dimanche	5	2024	16	5	10335	6353	3982
Angers	Reims	1462,26	1638,37	2	8	3,46	3,27	2,21	2,18	2024/2025	Stade Raymond-Kopa (Angers)	18752	dimanche	5	2024	18	1	9262	8526	736
Monaco	Lens	1772,99	1713,8	15	11	1,86	3,89	3,92	1,64	2024/2025	Stade Louis II (Monaco)	18523	dimanche	5	2024	16	1	11872	9030	2842
Angers	Nice	1468,79	1689,19	7	5	4,06	3,36	1,99	2,37	2024/2025	Stade Raymond-Kopa (Angers)	18752	dimanche	5	2024	18	1	11518	9168	2350
Monaco	Angers	1797,89	1497,76	10	6	1,21	7,06	13,02	1,45	2024/2025	Stade Louis II (Monaco)	18523	vendredi	11	2024	21	0	9234	10540	1306
Montpellier	Auxerre	1622,36	1541,53	2	6	2,32	3,46	3,06	1,83	2024/2025	Stade de la Mosson (Montpellier)	20484	dimanche	5	2024	19	1	13507	11643	1864
Reims	Rennes	1629,39	1693,1	8	7	2,92	3,44	2,4	1,86	2024/2025	Stade Auguste-Delaune (Reims)	21029	dimanche	5	2024	18	1	13898	12856	1042
Montpellier	Brest	1591,69	1721,23	0	7	3,27	3,51	2,18	1,85	2024/2025	Stade de la Mosson (Montpellier)	20484	dimanche	11	2024	19	1	12157	12936	779
Montpellier	Nantes	1649,05	1544,77	5	5	2,28	3,4	3,17	2,07	2024/2025	Stade de la Mosson (Montpellier)	20484	samedi	6	2024	20	1	14405	13000	1405
Monaco	Montpellier	1776,65	1622,36	13	4	1,34	5,59	8,22	1,47	2024/2025	Stade Louis II (Monaco)	18523	samedi	5	2024	22	1	9602	13065	3463
Monaco	St Etienne	1794,3	1513,77	12	8	1,5	4,64	6,1	1,66	2024/2025	Stade Louis II (Monaco)	18523	samedi	5	2024	22	1	11702	14250	2548
Brest	Nice	1721,23	1700,69	10	9	2,67	3,18	2,79	2,22	2024/2025	Stade Francis-Le Blé (Brest)	15220	samedi	11	2024	21	5	18962	14534	2428
Brest	Toulouse	1680,87	1633,68	6	5	2,14	3,51	3,38	2,02	2024/2025	Stade Francis-Le Blé (Brest)	15220	dimanche	5	2024	18	1	13767	14580	813
Reims	Lille	1636,88	1763,36	7	7	3,33	3,41	2,2	2	2024/2025	Stade Auguste-Delaune (Reims)	21029	samedi	6	2024	20	1	15363	14755	608
Angers	Lens	1477,82	1722,39	10	8	5,35	3,92	1,65	1,94	2024/2025	Stade Raymond-Kopa (Angers)	18752	dimanche	6	2024	18	1	13723	14811	1088
Brest	St Etienne	1707,59	1513,77	5	2	1,82	3,76	4,31	2,1	2024/2025	Stade Francis-Le Blé (Brest)	15220	samedi	6	2024	18	1	15830	14885	945
Brest	Marseille	1707,59	1727,5	8	10	2,88	3,4	2,46	1,92	2024/2025	Stade Francis-Le Blé (Brest)	15220	samedi	6	2024	18	1	20649	14962	5687
Auxerre	Brest	1541,53	1680,67	3	6	2,8	3,37	2,57	1,96	2024/2025	Stade de l'Abbé-Deschamps (Auxerre)	17924	vendredi	5	2024	20	0	13359	15381	2022
Montpellier	Strasbourg	1649,05	1611,99	8	3	2,08	3,39	3,64	2,02	2024/2025	Stade de la Mosson (Montpellier)	20484	dimanche	5	2024	18	1	13908	15706	1798
Auxerre	Angers	1609,7	1511,06	10	8	1,81	3,72	4,36	1,84	2024/2025	Stade de l'Abbé-Deschamps (Auxerre)	17924	dimanche	11	2024	19	1	16391	16120	271
Auxerre	Nice	1561,9	1705,9	13	8	3,14	3,21	2,39	2,25	2024/2025	Stade de l'Abbé-Deschamps (Auxerre)	17924	dimanche	6	2024	16	1	16349	16354	1995
Auxerre	Rennes	1576,91	1700,22	7	5	3,45	3,57	2,09	1,87	2024/2025	Stade de l'Abbé-Deschamps (Auxerre)	17924	dimanche	11	2024	19	1	16244	16866	122
Angers	Nantes	1462,26	1572	2	7	3,2	3,22	2,36	2,35	2024/2025	Stade Raymond-Kopa (Angers)	18752	dimanche	5	2024	18	1	9853	16942	7089
St Etienne	Le Havre	1513,77	1545,37	5	4	2,09	3,41	3,61	2,18	2024/2025	Stade Geoffroy-Guichard (Saint-Etienne)	42000	samedi	6	2024	22	1	28048	16958	11090
Auxerre	Monaco	1558,43	1772,99	7	13	3,88	3,89	1,89	1,52	2024/2025	Stade de l'Abbé-Deschamps (Auxerre)	17924	samedi	5	2024	20	1	17677	17045	632
Angers	Paris SG	1497,76	1909,6	8	13	11,59	6,49	1,24	1,45	2024/2025	Stade Raymond-Kopa (Angers)	18752	samedi	11	2024	23	1	19251	17212	2039
Nice	Strasbourg	1707,37	1624,69	9	4	1,81	3,73	4,37	1,85	2024/2025	Allianz Riviera (Nice)	36178	dimanche	11	2024	22	1	22289	18389	3900
Nice	Strasbourg	1707,37	1624,69	9	4	1,81	3,73	4,37	1,85	2024/2025	Allianz Riviera (Nice)	36178	dimanche	11	2024	22	1	22289	18389	3900

Ce tableau présente un extrait des données utilisées pour tester le modèle sur des matchs de la saison 2024/2025. Pour chaque match, le modèle a estimé l’affluence attendue (PredictedAttendance), à partir des données disponibles avant la rencontre : identités des équipes, scores Elo, forme récente (Form5Home, Form5Away), cotes de paris (OddHome, etc.), date, heure, capacité du stade et contexte temporel (week-end ou non).

La colonne attendance indique l’affluence réellement observée pour le match, tandis que Ecart_Affluence correspond à la différence entre la prédiction et la réalité.

On observe que, pour la grande majorité des matchs, l’écart reste raisonnable. Le modèle reproduit bien les grandes tendances : les grosses affiches (Nice vs Strasbourg, Monaco vs Brest, etc.) sont correctement estimées, et les matchs à moindre enjeu présentent des prédictions proches de la réalité.

Quelques écarts plus marqués apparaissent, comme le match Saint-Etienne – Le Havre, où l’affluence réelle a été très inférieure à la prédiction. Cela s’explique par une interdiction partielle de tribunes, un élément que le modèle ne pouvait pas anticiper (voir partie 3.3).

Ce tableau permet donc d’illustrer l’efficacité du modèle en conditions quasi-réelles, tout en soulignant ses limites face à des événements contextuels non modélisés.